

# گزارش تمرین سری سوم

اصول بینایی کامپیوتر

رضا اکبریان بافقی - ۹۵۱۰۰۰۶۱

با استفاده از سرویس آنلاین Colaboratory و با استفاده از لایبری tensorflow شبکه عصبی‌ای ساختم که دقت آن پس از ۵۰ epoch برابر ۹۹,۳۷٪ می‌شود. می‌توانید پارامترهای این شبکه را در جدول زیر مشاهده کنید.

Layer (type)	Output Shape	Param #
conv2d_4 (Conv2D)	(None, 28, 28, 128)	1280
activation_6 (Activation)	(None, 28, 28, 128)	0
max_pooling2d_4 (MaxPooling2D)	(None, 14, 14, 128)	0
conv2d_5 (Conv2D)	(None, 14, 14, 64)	73792
activation_7 (Activation)	(None, 14, 14, 64)	0
max_pooling2d_5 (MaxPooling2D)	(None, 7, 7, 64)	0
flatten_2 (Flatten)	(None, 3136)	0
dropout_2 (Dropout)	(None, 3136)	0
dense_4 (Dense)	(None, 100)	313700
batch_normalization_2 (Batch Normalization)	(None, 100)	400
dense_5 (Dense)	(None, 10)	1010
activation_8 (Activation)	(None, 10)	0
Total params: 390,182		
Trainable params: 389,982		
Non-trainable params: 200		

در این مدل، ابتدا یک لایه کانولوشنال با ۱۲۸ فیلتر روی تصویر اعمال می‌شود، برای هر فیلتر ۱۰ پارامتر داریم که می‌شود ۱۲۸۰ پارامتر در این مرحله. سپس از تابع فعال‌ساز ReLU استفاده می‌شود و با استفاده از MaxPooling با اندازه ۲ در ۲، اندازه تصویر نصف می‌شود و همچنین داده‌های اضافی را پاک می‌کند.

در لایه بعدی با این تفاوت که از ۶۴ فیلتر استفاده می‌کنیم و باقی مراحل را مانند لایه قبلی انجام می‌دهیم. حال عکس‌های ما تبدیل به مربع‌های ۷ در ۷ شده‌اند که از هرکدام آن‌ها ۶۴ فیلتر مختلف گذر کرده‌است. بنابراین با استفاده از Flatten آن‌ها را تبدیل به یک بردار می‌کنیم.

حال یک بردار ۳۱۲۶ بعدی داریم که می‌خواهیم با استفاده از یک لایه fully connected به ۱۰۰ نورون در لایه بعد متصل‌شان کنیم. که از Dense استفاده می‌کنیم. اما قبل از آن برای جلوگیری از overfitting و همچنین به‌دست آوردن شبکه‌ای با دقت بیش‌تر از Dropout استفاده می‌کنیم که در هر مرحله با احتمال ۰,۵ هر یک از نورون‌ها از آن ۳۱۲۶ نورون را خاموش می‌کند.


سپس بعد از آن دوباره ۱۰ نورون مشخص می‌کنیم و با استفاده دوباره از لایه fully connected این ۱۰۰ نورون را به این ۱۰ نورون وصل می‌کنیم. ولی قبل از آن عمل BatchNormalization را انجام می‌دهیم. چون ممکن است بر اثر Dropout

لایه قبلی مقادیر این لایه دچار تغییرات زیادی شود. این کار باعث شد تا دقت داده آموزشی و تست با هم بیشتر شود. ضمن این که سریع تر هم گرا شدند.

در نهایت با استفاده از تابع فعال ساز **softmax** احتمال هر کلاس برای داده مورد نظر را به دست می آوریم. سپس تابع **cross entropy** را به عنوان تابع **loss function** و بهینه ساز **Adam** را با نرخ یادگیری اولیه  $0.001$  در نظر می گیریم.

ما ابتدا داده ها را نرمال می کنیم و از  $0$  تا  $255$  به  $0$  تا  $1$  می بریم تا فرآیند آموزش شبکه سریع تر اتفاق بیافتد. سپس **label** های این تصاویر را تبدیل به بردار **one-hot** می کنیم. سپس مدل را مانند کاری که در بالا گفتیم تعریف می کنیم.

سپس برای فیت کردن داده ها، اندازه **batch** ها را  $256$  در نظر می گیریم. سایز این **batch** را طوری در نظر گرفتیم که به مشکل حافظه برنخوریم. می توانیم نمودار دقت این مدل را در **epoch** های مختلف در نظر بگیریم به شکل زیر در می آید.



شکل ۱ همان طور که می توانید مشاهده کنید بدون رخ دادن **overfitting** خطای داده تست به مرور کم تر شده است. و دقت داده تست (نارنجی) و دقت داده آموزشی (نارنجی) به مقدار معینی همگرا شده است.


هم چنین می توانید مقدار خطای روی داده تست و خطا روی داده آموزشی را در تعدادی از **epoch** ها ببینید.

```
Epoch 1/50
235/235 [=====] - 8s 36ms/step - loss: 0.5783 -
accuracy: 0.8241 - val_loss: 1.0962 - val_accuracy: 0.9645
Epoch 2/50
235/235 [=====] - 8s 34ms/step - loss: 0.1818 -
accuracy: 0.9500 - val_loss: 0.1881 - val_accuracy: 0.9763
Epoch 3/50
235/235 [=====] - 8s 34ms/step - loss: 0.1291 -
accuracy: 0.9647 - val_loss: 0.0770 - val_accuracy: 0.9815
.
.
.
Epoch 48/50
235/235 [=====] - 8s 33ms/step - loss: 0.0188 -
accuracy: 0.9943 - val_loss: 0.0212 - val_accuracy: 0.9927
Epoch 49/50
235/235 [=====] - 8s 33ms/step - loss: 0.0178 -
accuracy: 0.9944 - val_loss: 0.0194 - val_accuracy: 0.9932
Epoch 50/50
235/235 [=====] - 8s 33ms/step - loss: 0.0167 -
accuracy: 0.9948 - val_loss: 0.0196 - val_accuracy: 0.9937
```

در نهایت وقتی تابع `evaluate` را روی این مدل اعمال می‌کنیم، حاصل زیر را به عنوان دقت و خطای خروجی می‌دهد.

[0.01958615519106388, 0.9937000274658203]

من خواستم از `Data Augmentation` استفاده کنم ولی در نتیجه این شبکه نتوانست تاثیر بهتری بگذارد. ولی قبل از این که از `Dropout` استفاده کنم، دقت داده تست در مقداری کمتر از دقت آموزشی ثابت می‌شد، که می‌توانید دقت این شبکه قبل از اعمال لایه `Dropout` در شکل زیر مشاهده کنید. همچنین قبل از استفاده از `BatchNormalization` دقت شبکه در مقدار کمتر ۹۹٫۱۸٪ هم‌گرا می‌شد که با اعمال این لایه دقت تا ۹۹٫۳۷٪ افزایش یافت.



شکل ۲ دقت داده‌های تست (نارنجی) در مقابل دقت داده‌های آموزشی (آبی)، قبل از اعمال لایه `Dropout`

مدل در فایل `model.h5` ذخیره شده‌است. همچنین در فایل جویپتر `Q1.ipynb` جزئیات کار آورده شده‌است.

## بخش اضافی – Naive Bayes

من قبلاً با این داده `mnist` کار کرده بودم و توانسته بودم با استفاده از مدل `Naive Bayes` و استفاده از `Gaussian mixture model` به دقت ۹۶٫۲۷٪ برسم. که فایل جویپتر آن را در فایل جداگانه‌ای به نام `Q1_NaiveBayes_Optional.ipynb` قرار داده‌ام.